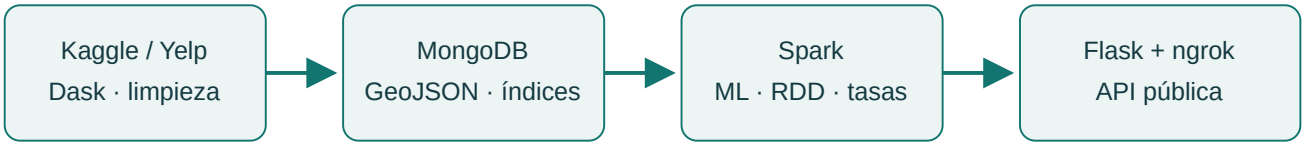
LifeMap: reputación, ubicación y supervivencia de negocios

Juan Echeverrri · Sebastian Botero
Institución Universitaria de Envigado · Ingeniería · 7 de noviembre de 2026

Propósito y alcance

Integrar ubicación, reputación textual y exposición temporal para consultar negocios y comparar tasas de cierre en el área de Yelp identificada por Florida (FL), familia **Restaurants**. El recorte usa el estado; no se aplicó una caja geográfica adicional. La vida se aproxima por las fechas de reseñas, pues Yelp no contiene apertura ni cierre reales.

Arquitectura y operación



Jenkins + GitHub: build → pruebas → staging → despliegue

Un Compose orquesta MongoDB, Spark maestro/worker, Dask scheduler/dos workers, Flask y Jenkins. La ingesta descarga y limpia; Spark entrena y agrega; Flask consulta MongoDB y carga el modelo compartido para inferencia. GitHub dispara Jenkins por webhook, con polling cada dos minutos como respaldo. Código en imágenes; datos y modelos en volúmenes; credenciales fuera de Git.

Resultado de la ejecución

Componente	Evidencia observada
Jenkins	Build #8: SUCCESS; API versión 8
Commit	b5f6745eef2efe51cfb53b3dcf4966337ac9008d
MongoDB / Spark / Dask	Estado ok; 1 worker Spark y 2 workers Dask
Datos	8.731 negocios y 792.133 reseñas; descarga completa automatizada
Sentimiento	Regresión logística guardada; /predict aprobado
Despliegue externo	Pendiente: el sistema aún corre en el portátil del equipo

Repositorio: github.com/Drkle/lifemap
API: https://aviation-decrease-hunger.ngrok-free.dev/health
Dashboard: /dashboard

El build y la comprobación pública son evidencia de funcionamiento en ese instante. No acreditan 48 horas de disponibilidad ni sustituyen el requisito de un servidor separado del portátil.

Datos, limpieza y vida observada

La descarga de `yelp-dataset/yelp-dataset` incluyó business.json (118.863.795 bytes) y review.json (5.341.868.833 bytes). Dask leyó **150.346 negocios y 6.990.280 reseñas**; procesó las 333 particiones de reseñas. Se conservaron todas las reseñas válidas del área/familia, no una muestra limitada a las primeras particiones. Tiempo de ingesta: **590,8 s**.

Descartes secuenciales

Tipo	Regla	Antes	Descartadas	Después
Negocios	N1_coord_nulas	150.346	0	150.346
Negocios	N2_coord_fuera_rango	150.346	0	150.346
Negocios	N3_fuera_area	150.346	124.016	26.330
Negocios	N4_sin_categoria	26.330	17.599	8.731
Negocios	N5_is_open_invalido	8.731	0	8.731
Negocios	N6_duplicado	8.731	0	8.731
Negocios	N7_sin_resenas	8.731	0	8.731
Reseñas	R1_negocio_no_valido	6.990.280	6.198.147	792.133
Reseñas	R2_texto_vacio	792.133	0	792.133
Reseñas	R3_estrellas_invalidas	792.133	0	792.133
Reseñas	R4_fecha_invalida	792.133	0	792.133
Reseñas	R5_duplicado	792.133	0	792.133

Se excluyen coordenadas inválidas, negocios fuera del recorte o sin la familia elegida, estado abierto/cerrado inválido y reseñas sin texto, estrellas/fechas válidas o identificador único. Las cifras cero indican reglas ejecutadas sin descartes en esta ejecución. Cada reseña referencia su negocio; cada negocio guarda un Point GeoJSON en orden longitud–latitud con índice `2dsphere`.

Reintentos y consistencia

Los bloques escriben por `review_id` con upsert idempotente. Repetir una tarea no descuenta documentos ya guardados. Los agregados de vida se calculan desde las reseñas únicas de MongoDB y se validan los conteos. Para controlar memoria se usan dos tareas activas, bloques de 16 MB y un hilo por worker; los argumentos del grafo se pueden reconstruir tras una caída.

Vida: primera a última reseña, contando ambos días. Se observaron 2.811 cierres y 5.920 negocios censurados, con 19.734.885 días-negocio; mediana de seguimiento de 2.115 días. Corte global del dataset: **19/01/2022, 19:48:45**.

Aperturas anteriores a la primera reseña generan entrada tardía no observada. Un abierto no se trata como cierre. En esta entrega, la exposición de la tasa usa primera–última reseña; se almacena además el seguimiento hasta el corte para estudiar censura en la segunda entrega.

Sentimiento: comparación sin fuga

Etiqueta: 1–2 estrellas = negativo; 3 = neutral; 4–5 = positivo. En las 792.133 reseñas: **69.04 % positivas, 20.53 % negativas y 10.43 % neutrales**. Se conserva el patrón de SentimentStream: tokenización y stopwords en inglés, HashingTF/IDF y clasificadores MLlib.

El muestreo aleatorio de entrenamiento conservó 300.361 reseñas (objetivo aproximado: 300.000). La separación se hizo por hash de `business_id`: 244.621 filas para entrenar y 55.740 para prueba, con **cero negocios compartidos**. IDF se ajustó solo en entrenamiento. Las clases se ponderaron por frecuencia inversa.

Modelo	Accuracy	F1 macro
Naive Bayes	0,7898	0,6746
Regresión logística	0,8215	0,7008

Resultados por clase

Modelo	Clase	Precisión	Recall	F1	Soporte
Naive Bayes	negativo	0.742	0.736	0.739	11.317
Naive Bayes	neutral	0.305	0.551	0.393	5.679
Naive Bayes	positivo	0.951	0.841	0.892	38.744
Regresión logística	negativo	0.782	0.785	0.783	11.317
Regresión logística	neutral	0.340	0.509	0.407	5.679
Regresión logística	positivo	0.948	0.878	0.912	38.744

Matriz: Naive Bayes

Real / Predicha	Negativo	Neutral	Positivo
Negativo	8.332	2.561	424
Neutral	1.293	3.129	1.257
Positivo	1.611	4.568	32.565

Matriz: regresión logística

Real / Predicha	Negativo	Neutral	Positivo
Negativo	8.880	1.936	501
Neutral	1.431	2.890	1.358
Positivo	1.046	3.680	34.018

Matrices: filas = etiqueta real; columnas = predicción. Orden: negativo, neutral, positivo. Métricas por clase calculadas desde los conteos de confusión de la consola; redondeo a tres decimales.

Interpretación y modelo activo

Se eligió **regresión logística** por su mayor F1 macro (+0,0262). Mejora F1 negativo a 0,783 y positivo a 0,912. Neutral sigue siendo la clase más difícil: precisión 0,340 y recall 0,509; de 5.679 neutrales reales, 2.890 se clasificaron correctamente, 1.431 como negativos y 1.358 como positivos. La precisión neutral baja evidencia falsos positivos y limita la interpretación de reseñas ambiguas.

La mayoría positiva hace insuficiente reportar solo accuracy. F1 macro pondera igual las tres clases, pero no reemplaza sus métricas individuales. El modelo se guardó en `/models/sentimiento_v1`, versión `20261107052058`; la API lo cargó y superó la prueba de predicción.

MapReduce, tasas y consultas espaciales

Exposición y fórmula

RDD emite `(clave, (evento, días_negocio, 1))` y suma con `reduceByKey` por categoría principal y geohash. Los resultados se contrastaron con `groupBy` de DataFrames; la prueba de la semilla validó valores conocidos antes de calcular los datos reales. El porcentaje de reseñas negativas por celda se agrega también por clave.

Tasa anualizada (%) = cierres ÷ (días-negocio ÷ 365) × 100

Resultado global: **2.811 cierres / (19.734.885 / 365) × 100 = 5,199** cierres por 100 años-negocio. La proporción de negocios cerrados es 32.20 %, pero esa proporción no es una tasa anualizada. Una tasa de exposición tampoco es la probabilidad individual de cierre en un año.

Para comparar grupos se exigen **18.250 días-negocio** (50 años-negocio). En ese umbral un cierre adicional mueve la tasa dos puntos porcentuales; reduce la sensibilidad extrema de grupos de exposición mínima, pero no elimina la incertidumbre por pocos eventos. El umbral es un parámetro de la API.

Categorías con mayor tasa entre grupos elegibles

Categoría	Negocios	Cierres	Años-negocio	Tasa (%)
Cajun/Creole	19	11	69.19	15.898
Restaurants	15	11	71.50	15.385
Tapas Bars	20	15	106.33	14.107
Buffets	29	23	171.65	13.399
Mediterranean	60	33	276.05	11.954
Indian	52	28	242.02	11.569

Fuente: /stats/closure en la comprobación pública. No interpretar el ranking como causalidad: categoría, ubicación y patrón de reseñas pueden afectar tanto la exposición medida como la selección de negocios.

Modelo geoespacial y operaciones

Endpoint	Operación y resultado
GET /businesses/near	$near: negocios por distancia; lat, lon, radio y categoría opcional
POST /businesses/within	$geoWithin: negocios dentro de un Polygon GeoJSON
GET /zones/summary	$geoNear + agregación: sentimiento medio y tasa cerca de un punto
GET /stats/closure	Tasas precalculadas por categoría o celda, con mínimo de exposición
POST /predict	Sentimiento de texto nuevo con el PipelineModel guardado
GET /health	Estado de servicios, modelo, versión y commit desplegado

La API valida coordenadas, radios, límites, polígonos y texto. Geohash de precisión 6 aporta celdas de aproximadamente 1,2 × 0,6 km según latitud. El dashboard web consulta automáticamente la API cada 15 segundos; las vistas de streaming permanecen vacías hasta ejecutar la segunda entrega.

Balanceo de carga: mediciones propias

Experimento sobre **792.133 reseñas**, Spark 3.5.3 y un worker con dos cores. Se cronometró la operación de agregación con 2, 8, 32 y 200 particiones, tres repeticiones por configuración. La tabla conserva los valores medidos del build #8, no resultados de una simulación.

Tiempos en segundos

Particiones	Repetición 1	Repetición 2	Repetición 3	Media	Desv. estándar
2	2.864	1.592	1.657	2.038	0.716
8	2.364	2.261	2.168	2.264	0.098
32	4.891	4.432	4.582	4.635	0.234
200	31.457	31.853	32.940	32.084	0.768

Filas por partición: 32 particiones

Reparto	Mínimo	Máximo	Media	Vacías	Máx./media
sin_clave	24.752	24.756	24754.2	0	1.0
por_ciudad	0	305.069	24754.2	1	12.32
por_categoria	161	106.082	24754.2	0	4.29

Interpretación

El reparto sin clave es casi uniforme: 24.752–24.756 filas por partición y relación máximo/media de 1,0. Por ciudad, una partición concentra 305.069 filas (12,32 veces la media) y otra queda vacía. Por categoría, el máximo llega a 106.082 (4,29 veces la media). Estos conteos sustentan el sesgo; no se infiere únicamente de los tiempos.

En este hardware, dos particiones dieron la menor media (2,038 s), seguidas de ocho (2,264 s). La primera repetición de dos fue 2,864 s frente a 1,592 y 1,657 s después: hay variabilidad y posible calentamiento. No se separó una fase de warm-up, por lo que una diferencia pequeña entre 2 y 8 no demuestra superioridad universal.

Con 200 particiones la media subió a 32,084 s, unas 15,7 veces el valor de dos. El mayor paralelismo potencial no se aprovecha en un worker de dos cores y añade planificación, serialización e intercambio. La recomendación se limita a esta carga y configuración; debe repetirse si cambia el tamaño del dataset o el clúster.

Reproducibilidad

`spark/jobs/balanceo.py` guarda tiempos individuales, medias, dispersión y distribución en MongoDB y exporta CSV a `/data/evidencias`. Los JSON revisados del repositorio incluyen las 12 repeticiones; el hash del texto aportado permite rastrear la fuente de los números.

No se alteraron los datos para obtener un reparto favorable. La comparación con/sin clave conserva el sesgo real de ciudad y categoría.

Despliegue, validación y pendientes

Ejecución CI/CD

El build #8 fue iniciado por un cambio SCM y terminó en **SUCCESS**. Cubrió construcción, pruebas API/ingesta/Spark, Kaggle, servicios, ingesta, integración, semilla determinista, cálculo real, staging y despliegue. La API candidata y la desplegada aprobaron /health y /predict. Kafka se omitió con `ENTREGA2=false`.

Comprobación de la URL pública

Fecha: **2026-11-07T00:27:58.916928-05:00** (America/Bogota). Los tiempos son observaciones de red de una sola consulta; no un benchmark de latencia.

Método / ruta	HTTP	Tiempo observado
GET /health	200	0.314 s
GET /businesses/near	200	0.272 s
POST /businesses/within	200	0.256 s
GET /zones/summary	200	0.315 s
GET /stats/closure	200	0.205 s
POST /predict	200	0.785 s

La respuesta de /health informó commit `b5f6745eef2efe51cfb53b3dcf4966337ac9008d`, versión 8, MongoDB/Spark/Dask/API en estado ok y modelo disponible. La consulta geográfica devolvió negocios reales de Tampa; tasas y predicción respondieron con datos del modelo entrenado.

Condiciones que aún no están acreditadas

1. **Bloqueo controlado:** ejecutar FORZAR_FALLO=true, conservar el build fallido y comprobar commit, versión e imagen antes/después. Los errores técnicos anteriores no sustituyen esta evidencia.
2. **Servidor independiente:** el sistema sigue en el portátil. La sección 6 del enunciado exige VM o equipo de laboratorio distinto. La URL ngrok no elimina esa dependencia.
3. **Disponibilidad:** sostener y registrar la URL al menos 48 horas antes de la evaluación y hasta terminar la sustentación. Esta verificación puntual no acredita esa ventana.

Limitaciones y continuación

Yelp no observa fechas reales de apertura/cierre; primera/última reseña son proxies y la entrada tardía no se conoce. La tasa de la primera entrega usa exposición por reseñas, mientras Kaplan-Meier deberá extender abiertos hasta el corte y tratar censura. El rollback restaura la imagen de API, no las mutaciones de datos/modelos compartidos; las recargas requieren mantenimiento. El modelo de sentimiento no reserva todavía datos posteriores a T en esta ejecución: se reentrenará con corte explícito antes del streaming.

Fuentes y trazabilidad

[1] Enunciado «LifeMap: reputación, ubicación y supervivencia de negocios», Big Data IUE 2026-2, secciones 4–7.
[2] Yelp Open Dataset, Yelp Inc., distribuido en Kaggle: yelp-dataset/yelp-dataset; uso académico sujeto a sus términos.
[3] Repositorio Drkle/lifemap, commit b5f6745; PR #5 y #6. Patrones del curso: SentimentStream (texto), trabajo geoespacial (Compose/API) y ejercicio de discos (MapReduce/tasa).
[4] Consola Jenkins lifemap-main #8 aportada por el equipo; datos extraídos en docs/evidencias/build8_resultados.json y comprobación externa en api_publica_build8.json.