LifeMap: reputación, ubicación y supervivencia de negocios

Santiago Villamizar Mejía · Juan Echeverri · Sebastián Botero
Institución Universitaria de Envigado · 2026-2

Resumen

LifeMap integra procesamiento distribuido, consultas geoespaciales, análisis de texto y streaming para estudiar negocios de restaurantes en Florida a partir de Yelp. La plataforma seleccionó 8.731 negocios y 792.133 reseñas. La ampliación temporal procesó una muestra real de 20.000 reseñas únicas, calculó riesgo para 3.972 negocios y persistió 1.738 ventanas cerradas. Power BI Desktop cargó y representó mapa, alertas, supervivencia y evolución de sentimiento.

Objetivo

Relacionar reputación, ubicación y seguimiento temporal mediante una plataforma reproducible. Se busca detectar variaciones negativas por zona y explorar asociaciones con un indicador de cierre, sin confundir predicción, causalidad y observación real.

Alcance de este documento

Borrador de avance para revisión del profesor. Resume resultados observados, decisiones y limitaciones. No declara terminados los requisitos de actualización automática de Power BI, disponibilidad de 48 horas ni sustentación. La ejecución permanece en el portátil del equipo; ello difiere del requisito de un servidor distinto al portátil de desarrollo.

Repositorio: github.com/Drkle/lifemap
API demostrada: aviation-decrease-hunger.ngrok-free.dev. La URL depende del túnel y del portátil encendido.

Arquitectura y preparación de los datos

Componente	Responsabilidad
Dask: scheduler y dos workers	Lectura particionada, filtrado y carga idempotente
MongoDB	Negocios y reseñas; índices 2dsphere; resultados y alertas
Spark: maestro y worker	Sentimiento, tasas de cierre y experimentos de particionado
Kafka KRaft + Structured Streaming	Tres particiones; business_id como clave; inferencia y ventanas
Flask + Jenkins	Consultas geoespaciales, salud, pruebas y despliegue
Power BI Desktop	Modelo Import conectado a la API y cuatro visuales

Flujo de información

Yelp → Dask → MongoDB → Spark/modelos; reseñas posteriores al corte → productor Kafka → Structured Streaming → MongoDB → Flask → Power BI. Docker Compose coordina servicios. Los modelos y checkpoints usan volúmenes persistentes y revisión de versiones.

Selección y limpieza

La lectura completa recorrió 150.346 negocios y 6.990.280 reseñas. Se conservaron restaurantes de Florida con ubicación válida y reseñas asociadas; quedaron 8.731 negocios y 792.133 reseñas. Se verificaron coordenadas, área, categoría, estado, estrellas, fechas y texto. La evidencia detallada antes/después de cada regla se conserva en el informe de la entrega 1 y build8_resultados.json.

Las escrituras por identificador y el recuento desde los documentos persistidos evitan inflar los totales en reintentos de Dask. El procesamiento se acotó a dos tareas en vuelo y bloques de 16 MB para adaptarse a la memoria del portátil.

Cortes temporales y modelos

Se fijó T = 1 de enero de 2019. La auditoría separó 510.850 reseñas históricas y reservó 281.283 para reproducción posterior. El entrenamiento de riesgo usa un corte anterior: 1 de enero de 2018. La selección de variables respeta cada corte; la separación por negocio evita que el mismo identificador aparezca en entrenamiento y prueba.

Sentimiento congelado

La regresión logística temporal obtuvo accuracy 0,8093 y F1 macro 0,6988. El consumidor carga la versión 20261107061724 y no la reentrena durante la reproducción. Los candidatos temporales se guardan separados del modelo histórico de la entrega 1; usar el histórico completo para reseñas de 2019 produciría fuga temporal.

Riesgo de cierre

Variables: sentimiento medio, tendencia negativa de seis meses, estrellas, cantidad de reseñas, edad desde la primera reseña y competidores de la misma categoría a 500 m. Se excluyen negocios sin actividad posterior al corte. La etiqueta positiva aproxima cierre en los siguientes doce meses mediante estado final y última reseña.

Indicador	Resultado
Entrenamiento / validación / prueba	3.320 / 1.051 / 1.073 negocios
Negocios cruzados entre conjuntos	0
AUC-ROC	0,5763
AUC-PR / prevalencia de referencia	0,0942 / 0,0792
Recall / umbral	0,3176 / 0,5656

El umbral maximiza F1 en validación del periodo anterior. El resultado tiene capacidad discriminativa limitada: supera poco la referencia de prevalencia. Las alertas son una herramienta exploratoria; no justifican decisiones automáticas sobre negocios.

Streaming y evidencia de operación

Tiempo del evento

El productor consulta reseñas posteriores a T, ordenadas por fecha e identificador, y admite límite y velocidad configurable. Kafka conserva la clave business_id. El consumidor aplica el modelo de sentimiento congelado y escribe por review_id para controlar duplicados. Un segundo flujo agrega ventanas de 30 días por geohash con watermark de 7 días; las ventanas se publican cuando cierran.

Definición de hotspot

Se marca una celda cuando el porcentaje de negativas aumenta al menos 15 puntos porcentuales respecto a la ventana anterior y ambas ventanas tienen al menos 20 reseñas. El mínimo reduce cambios extremos con volúmenes pequeños y el salto prioriza deterioros notorios. Son valores operativos iniciales: falta un análisis de sensibilidad que mida su estabilidad; no equivalen a significancia estadística.

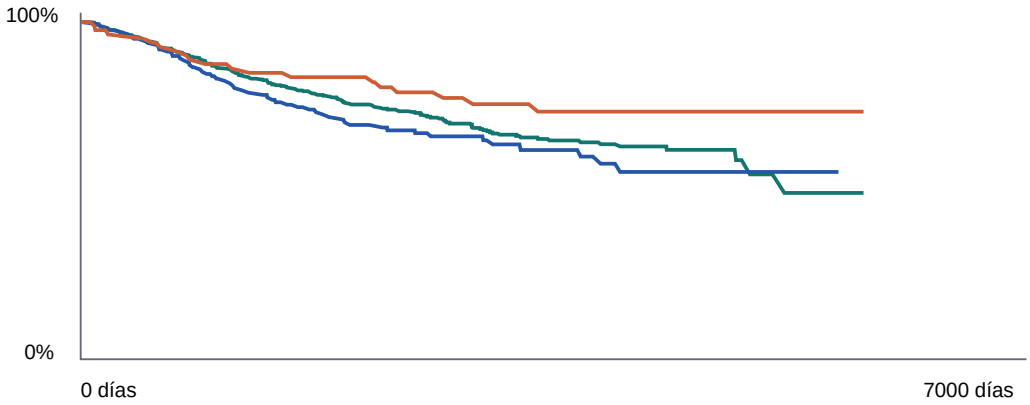
Prueba observada	Resultado
Jenkins #13: preparación temporal	SUCCESS; candidatos y prueba de 100 reseñas
Jenkins #14: versión inválida intencional	FAILURE esperado; despliegue bloqueado
Jenkins #19: activación de E2	SUCCESS; Kafka y cuatro endpoints aprobados
Reproducción real	20.000 reseñas únicas guardadas
Puntuaciones / ventanas cerradas	3.972 negocios / 1.738 ventanas
Salud al finalizar	Consumidor activo; tres particiones; lag 0

Se enviaron primero 1.000 reseñas y después las primeras 20.000 desde el mismo corte. El total persistido de 20.000 confirma que el reenvío no aumentó el número de documentos únicos en esta prueba. Hubo lotes más lentos que el intervalo de 5 segundos; posteriormente el consumidor alcanzó los offsets finales. Los resultados proceden de las consolas aportadas por el equipo, no de datos sintéticos.

Supervivencia por categoría y zona

Se consultó /survival/Pizza y se repitió con dos polígonos mediante POST. Las cajas delimitan zonas de análisis y no son fronteras administrativas oficiales. Los vértices exactos, las curvas y el número en riesgo en cada tiempo se conservan en supervivencia_zonas_20261107.json.

Cohorte Pizza	Negocios	Eventos	Mediana (días)
Pizza: total	523	159	5260
Pizza: zona Tampa	164	55	No alcanzada
Pizza: zona St. Petersburg	84	19	No alcanzada



■ Total Pizza · ■ Zona Tampa · ■ Zona St. Petersburg

Interpretación y cautelas

Kaplan–Meier estima continuidad del seguimiento desde la primera reseña. Los abiertos se censuran a la fecha de corte del dataset; los cerrados usan la última reseña como aproximación de salida. La mediana es el primer tiempo con supervivencia ≤ 0,5 y no se inventa si no se alcanza. Las diferencias entre zonas son descriptivas: no se han calculado intervalos de confianza ni contrastes formales.

Yelp no informa apertura real. El parámetro edad_previa_dias permite sensibilidad de entrada tardía; estas consultas usan 0, por lo que no prueban una corrección con edades reales. Tampoco puede interpretarse cada descenso como una fecha exacta de cierre. El tamaño en riesgo disminuye con el tiempo y limita la estabilidad del extremo de la curva.

Visualización en Power BI y consultas

El equipo abrió LifeMap.pbip en Power BI Desktop, convirtió el mapa Bing a Azure Maps y actualizó las consultas de forma anónima contra http://localhost:5000. Las capturas aportadas muestran las cuatro visualizaciones con datos, incluidos puntos sobre Tampa. La comprobación en Desktop complementa las pruebas estructurales del generador; estas últimas por sí solas no validan el renderizado.

Visual	Lectura e interpretación
Mapa de celdas y hotspots	Tamaño por volumen; leyenda de salto; tooltip de negativas ponderadas
Tabla de alertas	Probabilidad, umbral, fecha y versión por negocio; indicador proxy
Kaplan–Meier	Supervivencia por días para la categoría elegida
Evolución	Porcentaje negativo ponderado por reseñas en ventanas cerradas

Alcance espacial y agregación

Parámetros iniciales: Tampa, latitud 27,95; longitud −82,45; radio 5.000 m; categoría Pizza. Mapa, alertas y evolución usan el radio; la curva usa toda la categoría. No deben compararse como si fueran exactamente la misma cohorte. Las consultas espaciales tienen límite de 1.000 registros y fallan explícitamente si lo alcanzan para impedir totales truncados.

La medida de negativas calcula Σ(n × pct_negativas) / Σn y convierte la escala 0–100 a proporción antes de mostrar porcentaje. No promedia porcentajes de celdas con volúmenes distintos. La prueba HTTP inicial comprobó 91 ventanas, 99 alertas y 496 puntos KM en ese alcance; son filas de consultas, no los totales globales de MongoDB.

Actualización

Verificada: actualización manual con Actualizar. Import en Desktop no hace polling automático. El mecanismo de actualización automática en Power BI Service y su gateway/acceso aún no se han configurado ni demostrado. El dashboard web consulta automáticamente, pero no sustituye ese requisito de Power BI.

Conclusiones, pendientes y fuentes

La prueba real demuestra la integración de ingesta, inferencia, ventanas, persistencia y visualización. La reproducción pudo acumular retraso y después recuperarse hasta lag cero. Las puntuaciones de riesgo ofrecen señal limitada; el aporte principal comprobado es una plataforma reproducible que permite explorar reputación, ubicación y seguimiento temporal.

Reutilización de patrones del semestre

SentimentStream aporta el patrón de preparación de texto e inferencia con un modelo persistido. KafkaMed aporta el patrón de eventos, construcción de variables y alertas mediante foreachBatch. Los ejercicios geoespaciales aportan GeoJSON, índices 2dsphere, $geoNear y $geoWithin; MapReduce se reutiliza para tasas y experimentos de carga. Esta descripción indica patrones técnicos; el equipo debe explicar en la sustentación los cambios concretos respecto a sus ejercicios originales.

Pendiente o diferencia	Tratamiento antes de la entrega final
Power BI automático	Configurar mecanismo y demostrar que actualiza sin intervención
Servidor separado	El proyecto sigue en el portátil por decisión del equipo; solicitar validación del profesor
Disponibilidad 48 horas	Recoger mediciones continuas de la URL; no está demostrada aquí
Hotspots y supervivencia	Añadir sensibilidad de umbral y discusión de entrada tardía/muestras
Evidencias y sustentación	Conservar capturas, PBIX, artefactos de Jenkins y preparar modificación en vivo

Fuentes y trazabilidad

1. Enunciado LifeMap y diapositivas del curso proporcionados por el equipo: máximo 10 páginas para informe final.
2. Yelp Open Dataset, obtenido vía Kaggle: yelp-dataset/yelp-dataset.
3. docs/evidencias/build8_resultados.json; preparacion_build13.json; bloqueo_streaming_build14.json.
4. Consola Jenkins #19 y conteos MongoDB aportados por el equipo el 7 de noviembre de 2026.
5. docs/evidencias/supervivencia_zonas_20261107.json: respuestas API y polígonos reproducibles.
6. powerbi/validacion_api.json, proyecto PBIP y capturas Desktop aportadas en la sesión.

Estado: informe de avance para revisión; actualizar pendientes y anexar evidencias originales antes de presentarlo como informe final.